



Caso Práctico

Procesamiento del Lenguaje Natural (NLP)

Caso Práctico: Procesamiento del Lenguaje Natural (NLP)

Generación de modelos N-Gram

En el manual de la asignatura hemos estudiado los modelos N-Gram como modelos de lenguaje, es decir, modelos con la capacidad de predecir la siguiente palabra de una frase o de un conjunto de palabras.

Como hemos comentado, hay numerosas librerías y herramientas que nos permiten generar estos modelos sin necesidad de desarrollarlos nosotros mismos. Una de ellas, desarrollada en Javascript para navegador web es <https://www.reuneker.nl/files/ngram/>. Sigue los siguientes pasos y posteriormente responde a las preguntas.

1. Abre el siguiente cuento en este link (<http://web.seducoahuila.gob.mx/biblioweb/upload/Antoine%20de%20Saint-Exupery%20-%20El%20Principito.pdf>) y copia todo el texto (Ctrl+A) -> (Ctrl+C) del mismo
2. Accede al link del generador de N-gram (<https://www.reuneker.nl/files/ngram/>) y pega (Ctrl+V) el texto copiado en la ventana de “Input and settings”. Este será nuestro corpus.
3. Para la primera ejecución no modifiques ningún parámetro y pulsa el botón “Generate n-grams”. Verás a la derecha una tabla con todos los bigramas generados junto a su probabilidad.
4. Ahora, empleando el mismo texto, genera trigramas y tetragramas (3-gram y 4-gram).

Pregunta 1. ¿Qué diferencias observas entre la ejecución de 2-gram, 3-gram y 4-gram?

Pregunta 2. ¿Cuál de los tres modelos crees que sería más adecuado para la implementación de un modelo de lenguaje probabilístico y por qué?


Pregunta 3. Habrás notado que en el caso de los 4-gram los encabezados y pies de página afectan al resultado de nuestro modelo. ¿Cómo solucionarías esto?

Uso de GPT-2 como modelo generativo

Además de los modelos estadísticos tenemos la posibilidad de emplear modelos basados en mecanismos de atención para desarrollar capacidades generativas del lenguaje. De igual forma que los anteriores, hay numerosas opciones para usar e implantar directamente modelos de lenguaje sin necesidad de desarrollarlos nosotros mismos. Uno de los más accesibles dentro de la tecnología de los Transformers es GPT-2. Si bien su sucesor GPT-3, y GPT-4 son modelos mucho más potentes, el gran tamaño que tiene hace complicado ejecutarlo en servidores con capacidades estándar, así como ofrecerlo de forma gratuita fuera de la infraestructura de OpenAI.

Sin embargo, GPT-2 es un modelo más reducido, y se encuentra disponible en ubicaciones como HuggingFace, una comunidad de desarrolladores de IA que ponen a disposición de todo el mundo sus modelos tanto sin entrenar como pre entrenados.

Accederemos al modelo lite de GPT-2 en el link <https://huggingface.co/gpt2>. Veremos que a la derecha se encuentra una ventana de introducción de texto



Este texto es el contexto que recibe nuestro Transformer para generar la secuencia de salida. Es decir, los inputs que recibe para su ejecución.

Tarea 1. Introduce una secuencia de contexto **en inglés** y pulsa el botón “Compute”. El modelo completará tu frase con un texto completo en color azul. Repite este proceso con otra frase de contexto.

Pregunta 1. Comenta brevemente la impresión que has tenido de la ejecución de GPT-2. ¿Ha completado tu texto con una frase coherente? ¿Crees que es una generación de texto natural o aún es obvio que está producida por un algoritmo?

Pregunta 2. ¿Para qué usarías las capacidades de un algoritmo como GPT-2 conociendo sus limitaciones?

Pregunta 3. Relaciona los resultados de tus ejecuciones con los comentarios del equipo de desarrollo en la sección “Limitations and bias” dentro del mismo link.

Tarea 2. Accede ahora a la última versión gratuita de ChatGPT en <https://chatgpt.com/> y pídele que complete las mismas frases que le has pedido a GPT-2. Tu prompt puede ser algo como

“Te voy a proporcionar el comienzo de una frase. Complétala de forma creativa para que tenga sentido dado el contexto proporcionado.”

No obstante, te invito a generar tu propio prompt y a experimentar con él.

Pregunta 4. ¿Qué diferencias notas entre GPT-2 y la última versión? Desarrolla brevemente.

NER, Sentiment Analysis y POS Tagging para el análisis de Tweets

Por último, vamos a tratar de emplear modelos preentrenados de NLP para el análisis de mensajes cortos como pueden ser los tweets. Numerosas empresas emplean este tipo de modelos para analizar de forma masiva las opiniones que los usuarios vierten en las redes sociales.

Vamos a emplear dos tweets de prueba.

El primero será el siguiente “I am so disappointed with Burger King here in Houston, Texas. They just served me the worst hamburger with the coldest fries I’ve eaten. I’ll never come back.”

Y el segundo este “I am in love with this Siemens vacuum cleaner! It leaves no dust at all. Best purchase ever”

Vamos a pasar cada tweet por modelos de las tres tecnologías que necesitamos ejecutar.

1. Primero lo haremos por un analizador sintáctico o “POS Tagging”

Para ello emplearemos el siguiente modelo online

<https://parts-of-speech.info/>

Obtendremos el análisis sintáctico de ambos tweets al pulsar el botón “Pos-Tag!”

2. Después trataremos de descubrir entidades relevantes mediante un modelo de NER almacenado en la siguiente dirección <https://huggingface.co/dslim/bert-base-NER>

De igual forma introduciremos cada uno de los tweets y trataremos de extraer las entidades más relevantes.

3. Por último, analizaremos el sentimiento generalizado con el siguiente modelo de análisis de sentimientos basado en una modificación del modelo BERT denominado RoBERTa https://huggingface.co/SamLowe/roberta-base-go_emotions

Introduciremos cada uno de los tweets en el cuadro de entrada de texto y computaremos el resultado.

Pregunta 1. Ahora tenemos tanto el análisis sintáctico, como el NER y el análisis de sentimientos. ¿Qué conclusiones crees que podría sacar un algoritmo automatizado de análisis de opiniones gracias a estos tres algoritmos de NLP?

Pregunta 2. Habrás visto que algunos modelos funcionan mejor que otros. ¿Cuáles han funcionado mejor y cuáles peor? ¿Qué fallos te han llamado más la atención? ¿Crees poder imaginar el motivo por el que han podido fallar?

Pregunta 3. ¿Qué otros algoritmos de NLP crees que podrías usar para realizar una investigación acerca de las opiniones de los usuarios acerca de los productos de tu empresa?



CEUPE
Centro Europeo de Postgrado



Web

www.ceupe.com



E-mail

info@ceupe.com